

UNIVERSIDADE SANTO AMARO

GABRIEL BORGHI DE FREITAS OLIVEIRA

**ACURÁCIA DIAGNÓSTICA DE MODELOS DE
INTELIGÊNCIA ARTIFICIAL GENERATIVA E
MULTIMODAL NA INTERPRETAÇÃO DE
RADIOGRAFIAS DE TÓRAX:**

**Uma Revisão Sistemática e Meta-análise Exploratória Bivariada
Hierárquica**

**SÃO PAULO
2026**

GABRIEL BORGHI DE FREITAS OLIVEIRA

ACURÁCIA DIAGNÓSTICA DE MODELOS DE
INTELIGÊNCIA ARTIFICIAL GENERATIVA E
MULTIMODAL NA INTERPRETAÇÃO DE
RADIOGRAFIAS DE TÓRAX:

Uma Revisão Sistemática e Meta-análise Exploratória Bivariada
Hierárquica

Monografia de revisão sistemática e meta-
análise.

SÃO PAULO
2026

RESUMO

Objetivo: Estimar a acurácia diagnóstica de modelos de Linguagem Multimodal (VLMs) e de Linguagem de Grande Escala (LLMs) na interpretação de radiografias de tórax (CXR), por meio de revisão sistemática e meta-análise exploratória bivariada hierárquica, e identificar lacunas metodológicas na literatura primária que limitam sínteses quantitativas de maior robustez.

Métodos: A revisão foi desenhada e relatada em conformidade com as diretrizes PRISMA-DTA. A qualidade metodológica dos estudos foi avaliada pelo instrumento QUADAS-2. O modelo bivariado hierárquico de efeitos aleatórios (Reitsma et al.) foi estimado pelo método REML para os estudos com dados brutos completos (Raw 2×2). Foram incluídos 12 estudos primários; a análise principal de meta-análise formal restringiu-se aos 9 estudos com matrizes de confusão disponíveis, totalizando 113.714 radiografias de tórax.

Resultados: O modelo bivariado estimou sensibilidade agrupada de 78,1% (IC 95%: 54,9–91,3%) e especificidade agrupada de 96,8% (IC 95%: 89,1–99,1%), com área sob a curva (AUC) SROC de 0,953, razão de verossimilhança positiva (RV+) de 24,10 e razão de verossimilhança negativa (RV-) de 0,226. O intervalo de predição de 95% para a sensibilidade foi amplo, variando de 6,4% a 99,5% ($\tau_{\text{sens}} = 1,583$), indicando alta heterogeneidade entre os estudos. Na análise de sensibilidade que excluiu o estudo de maior peso amostral (Huang 2025, N=97.651, prevalência = 0,03%), a sensibilidade foi de 79,2% (IC 95%: 52,8–92,8%) e a especificidade de 93,7% (IC 95%: 91,0–95,6%), com RV+ de 12,54 e AUC de 0,950. Apenas 9 dos 12 estudos identificados disponibilizaram dados brutos para pooling formal.

Conclusão: Os modelos avaliados foram associados a estimativas de sensibilidade e especificidade clinicamente relevantes em tarefas de triagem radiológica torácica. A especificidade do pool completo (96,8%) é dependente do perfil de um único estudo de prevalência extremamente baixa (Huang 2025); o cenário sem esse estudo (especificidade de 93,7%) é mais representativo de contextos clínicos habituais. As probabilidades pós-teste calculadas para diferentes prevalências pré-teste a partir das razões de verossimilhança do pool principal podem ser visualizadas no Nomograma de Fagan da Figura 10. A baixa sensibilidade observada para lesões pequenas (ex: nódulos ou pneumotórax sutil) impede o uso desses modelos como ferramentas isoladas de exclusão (rule-out). O uso como segunda leitura assistida, sob supervisão médica, constitui o modelo compatível com a evidência disponível.

Palavras-chave: Inteligência Artificial Generativa. Modelos de Linguagem Multimodal. Radiografia de Tórax. Meta-análise. Acurácia Diagnóstica. PRISMA-DTA.

ABSTRACT

Objective: To estimate the diagnostic accuracy of Vision-Language Models (VLMs) and Large Language Models (LLMs) in chest radiograph interpretation through a systematic review and hierarchical bivariate exploratory meta-analysis, and to identify methodological gaps in the primary literature that limit more robust quantitative syntheses.

Methods: The review was conducted in accordance with PRISMA-DTA guidelines. Methodological quality was assessed using QUADAS-2. The hierarchical bivariate random-effects model (Reitsma et al.) was estimated by REML for studies with complete raw 2×2 data. Twelve primary studies were included; the bivariate analysis was restricted to the nine with complete 2×2 data, totaling 113,714 radiographs.

Results: The bivariate model estimated a pooled sensitivity of 78.1% (95% CI: 54.9–91.3%) and pooled specificity of 96.8% (95% CI: 89.1–99.1%), with AUC SROC=0.953, LR+=24.10, and LR-=0.226. The 95% prediction interval for sensitivity ranged from 6.4% to 99.5%. In the sensitivity analysis excluding the study with the highest sample weight (Huang 2025, N=97,651, prevalence=0.03%), results were: sensitivity 79.2% (95% CI: 52.8–92.8%), specificity 93.7% (95% CI: 91.0–95.6%), LR+=12.54, and AUC=0.950.

Conclusion: The evaluated VLM and LLM models were associated with clinically relevant sensitivity and specificity estimates in thoracic radiological screening tasks. Use as an assisted second reading under mandatory radiological supervision constitutes the model of use consistent with available evidence.

Keywords: Generative Artificial Intelligence. Vision-Language Models. Chest Radiograph. Meta-analysis. Diagnostic Accuracy. PRISMA-DTA.

ÍNDICE

1	INTRODUÇÃO	8
1.1	Contextualização Clínica	8
1.2	Evolução para Modelos Multimodais	8
1.3	Desafios Atuais na Interpretação Automatizada	8
1.4	Objetivos	9
2	MÉTODOS	10
2.1	Desenho e Conformidade Normativa	10
2.2	Estratégia de Busca e Critérios de Elegibilidade (PIRT)	10
2.3	Avaliação do Risco de Viés pelo QUADAS-2	11
2.4	Modelo Estatístico	11
2.5	Tratamentos Matemáticos Específicos	12
2.6	Heterogeneidade e Curva SROC	12
2.7	Análises de Sensibilidade	12
2.8	Utilidade Clínica pelo Nomograma de Fagan	13
2.9	Métricas de Avaliação Qualitativa e Quantitativa para Modelos Generativos	13
2.10	Reprodutibilidade e Ciência Aberta	13
3	RESULTADOS	14
3.1	Características dos Estudos e Avaliação QUADAS-2	14
3.2	Meta-análise Exploratória: Pool Principal (N=9)	17
3.3	Análises de Sensibilidade	20
3.4	Heterogeneidade	21
3.5	Análise Exploratória por Subgrupos	22
3.5.1	Por Arquitetura	22
3.5.2	Por Condição Clínica	24
3.5.3	Por Tamanho e Gravidade da Lesão	25
3.5.4	Por Grupo Demográfico	25
3.6	Impacto no Fluxo de Trabalho (Workflow) Clínico	25
3.7	Qualidade Textual e Alucinações nos Laudos Gerados	26
4	DISCUSSÃO	27
4.1	Interpretação das Estimativas	27
4.2	Implicações da Dominância Amostral	27
4.3	Perfis por Arquitetura	28
4.4	O Impacto da Engenharia de Prompts	29
4.5	Ferramenta Diagnóstica Isolada vs. Colaboração Humano-IA	29
4.6	Lacunas da Literatura Primária	31

4.7	Limitações	31
4.8	Implicações Regulatórias e Governança	32
5	CONCLUSÃO	33

LISTA DE FIGURAS

1	Fluxograma PRISMA-DTA de Seleção dos Estudos.	14
2	QUADAS-2: Avaliação Individual por Estudo e Domínio.	16
3	QUADAS-2: Resumo por Domínio (N=12).	17
4	Forest Plot da Sensibilidade Agrupada (N=9, Raw 2×2).	18
5	Forest Plot da Especificidade Agrupada (N=9, Raw 2×2).	19
6	Curva SROC Hierárquica e Regiões de Confiança e Predição: Pool Principal (N=9).	20
7	Funnel Plot para Avaliação de Viés de Publicação e Assimetria de Relato. .	22
8	Bubble Plot: Sensibilidade × Especificidade × Tamanho da Amostra. . .	23
9	Comparativo de Desempenho por Arquitetura de IA: VLM vs. LLM. . .	24
10	Nomograma de Fagan: Probabilidades Pós-teste para Cenários Clínicos. .	28

LISTA DE TABELAS

1	Características dos Estudos Bivariados Incluídos (N=9)	15
2	Desempenho Diagnóstico Individual dos Estudos	15
3	Avaliação da Qualidade Metodológica dos Estudos pelo Instrumento QUADAS- 2 (N=12)	16
4	Resultados Meta-analíticos Agrupados do Pool Principal (N=9)	17
5	Resultados das Análises de Sensibilidade (Robustez)	20
6	Análise Exploratória por Subgrupo de Arquitetura (N=9)	23
7	Análise Exploratória por Subgrupo de Condição Clínica (N=9)	25

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
ANVISA	Agência Nacional de Vigilância Sanitária
AUC	Area under the curve (Área sob a curva)
BERTScore	Bidirectional Encoder Representations from Transformers Score (métrica de avaliação textual)
BLEU	Bilingual Evaluation Understudy (métrica de similaridade de texto)
CAD	Computer-aided detection (Detecção assistida por computador)
CNN	Convolutional neural network (Rede neural convolucional)
CXR	Chest X-ray (Radiografia de tórax)
DICOM	Digital Imaging and Communications in Medicine
DOR	Diagnostic odds ratio (Razão de chances diagnóstica)
FN	Falso negativo
FP	Falso positivo
IC	Intervalo de confiança
LLM	Large Language Model (Modelo de linguagem de grande escala)
NLP	Natural language processing (Processamento de linguagem natural)
NPV	Negative predictive value (Valor preditivo negativo)
PI	Prediction interval (Intervalo de predição)
PIRT	Participantes, Índice, Referência, Condição-alvo
PLN	Processamento de linguagem natural
PPV	Positive predictive value (Valor preditivo positivo)
PRISMA-DTA	Preferred Reporting Items for Systematic Reviews – Diagnostic Test Accuracy
PROSPERO	International Prospective Register of Systematic Reviews
QUADAS-2	Quality Assessment of Diagnostic Accuracy Studies 2
REML	Restricted maximum likelihood (Máxima verossimilhança restrita)
RV-	Razão de verossimilhança negativa
RV+	Razão de verossimilhança positiva
SaMD	Software as a Medical Device (Software como dispositivo médico)
SROC	Summary receiver operating characteristic
STARD	Standards for Reporting Diagnostic Accuracy
TF-IDF	Term frequency–inverse document frequency
VLM	Vision-Language Model (Modelo de linguagem multimodal com visão)
VN	Verdadeiro negativo
VP	Verdadeiro positivo

1 INTRODUÇÃO

1.1 Contextualização Clínica

A radiografia de tórax (CXR) é o exame de imagem médica mais realizado no mundo, representando parcela substancial dos procedimentos radiológicos executados anualmente [1]. O elevado volume de exames, combinado com a escassez global de médicos radiologistas, impõe gargalos críticos aos sistemas de saúde, resultando em atrasos na emissão de laudos que impactam a eficiência do cuidado primário, emergencial e hospitalar. O impacto dessa sobrecarga sobre os profissionais é documentado na literatura científica: as taxas de esgotamento profissional (burnout) na radiologia mantêm-se consistentemente elevadas em relação à média dos demais especialistas, afetando cerca de metade dos radiologistas em prática ativa [2]. A fadiga cognitiva decorrente da leitura contínua e apressada de exames é apontada como um dos principais fatores de risco para erros de interpretação diagnóstica, ressaltando a necessidade de ferramentas de suporte que otimizem o fluxo de trabalho.

1.2 Evolução para Modelos Multimodais

A automação da análise de imagens radiológicas baseou-se historicamente em sistemas de detecção assistida por computador (CAD) e, posteriormente, no desenvolvimento de redes neurais convolucionais (CNNs). Embora eficazes em tarefas específicas, estes algoritmos tradicionais apresentam limitações estruturais inerentes: operam predominantemente em modo de classificação binária ou segmentação de caixas delimitadoras, sem capacidade de gerar narrativa diagnóstica estruturada, integrar múltiplos achados clínicos secundários ou contextualizar informações clínicas complexas.

Os avanços recentes em inteligência artificial generativa permitiram a transição para Modelos de Linguagem Multimodal de Grande Escala (VLMs) e Modelos de Linguagem de Grande Escala (LLMs). Ao integrarem um codificador visual (image encoder) e um decodificador de texto (text decoder) em uma arquitetura de transformadores (transformers) unificada, esses sistemas são capazes de receber imagens de raios-X e gerar diretamente laudos radiológicos preliminares completos e estruturados em linguagem natural, além de permitir interações de perguntas e respostas textuais dinâmicas sobre os achados de imagem.

1.3 Desafios Atuais na Interpretação Automatizada

Apesar do grande potencial demonstrado, a aplicação clínica de VLMs e LLMs de propósito geral enfrenta desafios científicos específicos. Primeiramente, destaca-se o fenômeno das alucinações (hallucinations), no qual os modelos generativos descrevem achados patológicos inexistentes ou citam incorretamente a presença de dispositivos médicos e exames prévios de comparação [3]. Em segundo lugar, os modelos demonstram grande sensibilidade à

presença de contexto clínico: a acurácia de leitura de imagem pode degradar drasticamente se informações básicas (como sintomas e motivo do exame) forem omitidas ou incorretamente formuladas na engenharia de prompts. Por fim, a integração multimodal de pixels de alta definição com conceitos textuais clínicos ainda sofre de falta de alinhamento espacial refinado, prejudicando a capacidade dos modelos generativos de localizar lateralidades (esquerdo vs. direito) e identificar lesões sutis ou pouco conspícuas.

1.4 Objetivos

O objetivo primário desta revisão sistemática com meta-análise é estimar, por meio de modelagem bivariada hierárquica em conformidade com as diretrizes PRISMA-DTA [4], a acurácia diagnóstica global de modelos de IA generativa e multimodal (VLMs/LLMs) na interpretação de radiografias de tórax em pacientes adultos, expressa pelos pares combinados de sensibilidade e especificidade agrupadas e pelas razões de verossimilhança (RV+, RV-).

Os objetivos secundários são:

1. Avaliar a qualidade metodológica dos estudos incluídos utilizando o instrumento QUADAS-2 [5];
2. Analisar o desempenho dos subgrupos por arquitetura (modelos de propósito geral vs. específicos/adaptados de domínio) e por condição clínica;
3. Investigar a influência do tamanho da lesão, gravidade e demografia na acurácia relatada;
4. Avaliar o impacto das ferramentas de IA generativa no fluxo de trabalho clínico (tempo de leitura e concordância interobservador);
5. Identificar as lacunas metodológicas de reporte na literatura primária que limitam sínteses quantitativas robustas.

2 MÉTODOS

2.1 Desenho e Conformidade Normativa

Este estudo constitui uma revisão sistemática com meta-análise de acurácia diagnóstica conduzida em estrito alinhamento com as recomendações do *Preferred Reporting Items for Systematic Reviews and Meta-Analyses for Diagnostic Test Accuracy* (PRISMA-DTA) [4] e os princípios do *Standards for Reporting Diagnostic Accuracy* (STARD) [6]. Para subsidiar a análise de modelos multimodais de imagem aplicados ao tórax, recorreu-se aos princípios norteadores recém-propostos do framework PRIME 2.0 [7] (*Proposed Requirements for Cardiovascular Imaging-Related Multimodal AI Evaluation*), que estabelece diretrizes para a transparência do reporte de prompts, parâmetros de inferência e controle de alucinações em IAs generativas de imagem médica. O protocolo não foi registrado prospectivamente no PROSPERO devido ao caráter exploratório e à constatação de elevada heterogeneidade de dados no levantamento inicial da literatura primária. O protocolo desta revisão sistemática foi posteriormente registrado no Open Science Framework (OSF) sob o DOI: 10.17605/OSF.IO/U6BJS. Todos os dados, códigos analíticos e materiais suplementares utilizados para garantir a reprodutibilidade desta pesquisa estão publicamente disponíveis no repositório GitHub, espelhados no projeto OSF (<https://osf.io/sh5z7>).

2.2 Estratégia de Busca e Critérios de Elegibilidade (PIRT)

A busca sistemática de artigos foi realizada nas bases PubMed/MEDLINE, SciELO e BVS, com escopo temporal congelado por data de publicação entre 30 de novembro de 2022 — data do lançamento público do ChatGPT, marco inicial da era de IA generativa — e 9 de junho de 2026. A data de corte é fixa, e não “a data corrente”, de modo que a reexecução da busca em qualquer momento futuro devolve a mesma janela de registros. A triagem inicial de títulos e resumos foi automatizada, de forma determinística, por meio de um pipeline de Processamento de Linguagem Natural (PLN) baseado em Term Frequency-Inverse Document Frequency (TF-IDF); a avaliação de elegibilidade por texto completo e a subsequente extração de dados foram conduzidas por um único revisor. A elegibilidade dos estudos primários baseou-se nos critérios PIRT:

- **P (Participantes):** Pacientes adultos que realizaram radiografia de tórax frontal (PA ou AP);
- **I (Índice):** Modelos de inteligência artificial generativa e multimodal (VLMs ou LLMs de imagem), operados de forma independente ou como assistentes de laudo (ex: GPT-4o, Gemini 2, Claude 3.7, LLaVA-Rad, KARA-CXR);
- **R (Referência):** Padrão-ouro definido por consenso de radiologistas seniores, tomografia computadorizada (TC) de tórax ou laudo final validado em prontuário eletrônico;

- **T (Condição-alvo):** Presença de patologias torácicas comuns ou agudas (pneumotórax, pneumonia, nódulo pulmonar, tuberculose).

Os estudos foram divididos em: (a) Pool Principal (N=9 estudos com matrizes de contingência 2×2 brutas de verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos disponíveis ou calculáveis); e (b) Pool Suplementar/Qualitativo (N=3 estudos elegíveis que relataram apenas métricas globais de acurácia, curvas ROC parciais ou análises de fluxo de trabalho sem disponibilização das matrizes brutas).

Para a análise exploratória por arquitetura, cada estudo foi classificado conforme a caracterização do modelo-índice pelos autores primários: como *Vision-Language Model* (VLM) quando o índice é descrito como modelo multimodal com codificador visual que recebe a imagem diretamente (ex.: GPT-4o, Gemini 2, Claude, KARA-CXR, CXR-LLaVA), e como *Large Language Model* (LLM) de propósito geral quando o índice é descrito como sistema generativo de rascunho/laudo em que um codificador visual próprio não constitui o teste-índice reportado (Huang 2023 e Huang 2025). Por depender da nomenclatura dos estudos primários e por incluir apenas dois estudos no braço LLM, essa estratificação tem caráter estritamente exploratório e não suporta inferência comparativa formal entre arquiteturas.

2.3 Avaliação do Risco de Viés pelo QUADAS-2

O risco de viés e a aplicabilidade clínica dos estudos primários foram avaliados pelo instrumento QUADAS-2 [5], estruturado em quatro domínios principais: (1) Seleção de Pacientes; (2) Teste de Índice; (3) Padrão de Referência; e (4) Fluxo e Tempo. Os domínios 1, 2 e 3 também foram avaliados em relação à aplicabilidade clínica. A extração dos dados e o julgamento do risco de viés foram realizados por um único revisor. Consequentemente, a concordância interavaliador (kappa de Cohen) não pôde ser calculada, e a avaliação QUADAS-2 é reportada sob revisor único, o que constitui limitação metodológica declarada (ver Seção de Limitações).

2.4 Modelo Estatístico

A síntese quantitativa das estimativas de acurácia diagnóstica do pool principal foi conduzida por meio do modelo bivariado hierárquico de efeitos aleatórios proposto por Reitsma et al. [8], estimado via método de máxima verossimilhança restrita (REML). O modelo bivariado preserva a bidimensionalidade natural dos dados de acurácia diagnóstica ao modelar simultaneamente a sensibilidade e a taxa de falsos positivos (1 - especificidade) na escala *logit*, ajustando a correlação intrínseca entre as métricas induzida pelo limiar de decisão implicitamente adotado pelos estudos. Os parâmetros do modelo estimam o ponto sumário da sensibilidade e especificidade, bem como a elipse de confiança de 95% e o intervalo de predição de 95% na escala ROC.

2.5 Tratamentos Matemáticos Específicos

Visando contornar a indeterminação matemática de células nulas nas matrizes 2×2 individuais (divisão por zero na escala logit), aplicou-se a correção de continuidade de Haldane-Anscombe de 0,5. A correção é acionada pelo estudo de Ciflik et al. (2026) [9], que relatou zero falsos negativos (sensibilidade bruta de 100,0%). Registre-se que a implementação utilizada (`mada::reitsma`) opera, por padrão, com `correction.control = "all"`: uma vez acionada, a constante de 0,5 é somada às células de **todos** os estudos do pool, e não apenas às do estudo que apresenta a célula nula. Para Ciflik, o procedimento resulta em sensibilidade corrigida de 98,4% (30,5/31), garantindo a estabilidade e a convergência numérica do algoritmo de otimização do modelo de Reitsma. As estimativas apresentadas nas Tabelas 1 e 2 correspondem aos dados brutos extraídos dos estudos primários, sem a aplicação da correção.

2.6 Heterogeneidade e Curva SROC

A heterogeneidade estatística foi avaliada por meio da curva de característica de operação do receptor sumária (SROC) hierárquica e quantificada pelo índice I^2 utilizando três metodologias complementares propostas na literatura [10]: o método de Zhou-Dendukuri (focado na variabilidade entre os estudos), o método de Holling não ajustado (sensível a diferenças de proporções absolutas) e o método de Holling ajustado pelo tamanho amostral. O cálculo do intervalo de predição de 95% (PI) foi implementado na escala logit utilizando a distribuição t de Student com $n - 2$ graus de liberdade (sendo n o número de estudos incluídos), conforme a fórmula:

$$PI = \hat{\theta} \pm t_{n-2, 0.975} \times \sqrt{\tau^2 + EP^2} \quad (1)$$

onde $\hat{\theta}$ representa o estimador na escala logit, τ^2 a variância de efeitos aleatórios entre estudos e EP o erro padrão do estimador. Os valores foram posteriormente retrotranspostos para a escala de probabilidade pela função logística (*expit*).

2.7 Análises de Sensibilidade

Para avaliar a estabilidade do ponto sumário e identificar a influência de potenciais outliers, foram conduzidas cinco análises de sensibilidade pré-especificadas:

- **Cenário A:** Exclusão de Güzel 2026 [11] (estudo com sensibilidade atipicamente baixa e grande volume amostral);
- **Cenário B:** Exclusão de Huang 2025 [12] (estudo prospectivo de prevalência extremamente baixa e responsável pela maior parcela amostral de exames normais);
- **Cenário C:** Exclusão simultânea de Güzel 2026 e Huang 2025 (cenário sem os dois principais extremos de peso amostral);

- **Cenário D:** Exclusão de estudos classificados com alto risco de viés em qualquer domínio do QUADAS-2 (Akçay 2025 [13] e Khovanova 2026 [14]);
- **Cenário E:** Restrição da análise exclusivamente ao subgrupo de estudos de pneumotórax (N=5 estudos).

2.8 Utilidade Clínica pelo Nomograma de Fagan

A utilidade clínica prática dos modelos multimodais de IA foi avaliada pelo Nomograma de Fagan (nomograma de atualização bayesiana). As razões de verossimilhança positiva (RV+) e negativa (RV-) derivadas do ponto sumário meta-analítico foram aplicadas a probabilidades pré-teste clinicamente relevantes de 5% (contexto de triagem ambulatorial de baixa prevalência), 10% (pronto-socorro geral de baixo risco) e 20% (pronto-socorro de alta prevalência ou pós-triagem por enfermaria de emergência), calculando-se as correspondentes probabilidades pós-teste positivo e pós-teste negativo.

2.9 Métricas de Avaliação Qualitativa e Quantitativa para Modelos Generativos

Ao contrário dos modelos de classificação de aprendizado profundo tradicionais, as IAs generativas produzem texto em formato livre, o que exige métricas de avaliação adicionais. No âmbito linguístico (NLP), foram descritas métricas como o BLEU-4 (similaridade de n-gramas) e o BERTScore (similaridade baseada em embeddings contextuais de modelos de linguagem) para aferir a correspondência semântica e sintática entre os laudos gerados pela IA e os escritos por radiologistas humanos.

No âmbito clínico, foram analisadas duas métricas principais: a classificação RAD-PEER (escore de 1 a 5 de concordância clínica utilizado no controle de qualidade radiológico, variando de discrepância clinicamente significativa a concordância completa) e as Escalas Likert de 5 pontos, utilizadas por avaliadores humanos cegados para graduar a acurácia diagnóstica, clareza e legibilidade geral do texto do relatório médico gerado pela máquina.

2.10 Reprodutibilidade e Ciência Aberta


Alinhado aos princípios da Ciência Aberta e visando garantir a reprodutibilidade integral da presente revisão sistemática e meta-análise, todo o pipeline de busca sistemática por processamento de linguagem natural (PLN), os dados brutos de extração das tabelas 2×2, a avaliação QUADAS-2 e os scripts estatísticos R do modelo bivariado hierárquico foram disponibilizados publicamente em um repositório no GitHub (<https://github.com/Borghi2000/metaanalysis>), sob a licença MIT, com arquivo permanente de dados e código registrado sob o Identificador de Objeto Digital (DOI) de versionamento <https://doi.org/10.5281/zenodo.19115371> via plataforma Zenodo.

3 RESULTADOS

3.1 Características dos Estudos e Avaliação QUADAS-2

A busca sistemática e a triagem recuperaram 12 estudos primários elegíveis publicados entre 2023 e 2026, conforme detalhado no fluxograma de seleção apresentado na Figura 1. A Tabela 1 apresenta as características gerais dos estudos bivariados incluídos no pool principal (N=9, totalizando 113.714 exames avaliados). O pool suplementar é composto por 3 estudos: Lee 2025 [15] (N=3.689), Bai 2026 [16] (N=296) e Bulut 2025 [17] (N=172), cujos dados de matriz 2×2 completos não estavam declarados.

Figura 1 – Fluxograma PRISMA-DTA de Seleção dos Estudos.



Busca real PubMed (2026-06-09); SciELO/BVS retornaram 0. Triagem de título/resumo AUTOMATIZADA (TF-IDF + cosseno, limiar 0.04), reproduzível pelo código. Elegibilidade por texto completo (revisor) aplicando critérios PIRT do protocolo. Fonte dos números: data/processed/prisma_counts.json.

Fonte: Elaborado pelo autor (2026).

Tabela 1 – Características dos Estudos Bivariados Incluídos (N=9)

Estudo	Arquitetura	Cenário Clínico	N Total	VP	FP	FN	VN
Hong 2025a [18]	VLM	Pneumotórax	2.145	181	142	9	1.813
Hong 2025b [19]	VLM	Triagem de Tuberculose	800	360	56	18	366
Ostrovsky 2025 [3]	VLM	Pneumonia vs. Normal	1.400	141	77	44	1.138
Huang 2023 [20]	LLM	Raio X Emergência	500	139	5	25	331
Huang 2025 [12]	LLM	Pneumotórax (Prospective)	97.651	24	22	9	97.596
Akçay 2025 [13]	VLM	Pneumotórax (spontaneous)	220	78	4	32	106
Ciflik 2026 [9]	VLM	Pneumotórax (real-world)	240	30	18	0	192
Güzel 2026 [11]	VLM	Pneumotórax (SIIM-ACR)	10.675	523	415	1.856	7.881
Khovanova 2026 [14]	VLM	Nódulo Pulmonar	83	12	3	26	42

Fonte: Elaborado pelo autor (2026), com base nos estudos primários citados.

O desempenho de acurácia diagnóstica estimado de forma individual para cada estudo primário é detalhado na Tabela 2, evidenciando elevada dispersão dos resultados, com a sensibilidade individual variando de 22,0% a 100,0% e a especificidade de 86,7% a 100,0%.

Tabela 2 – Desempenho Diagnóstico Individual dos Estudos

Estudo	Sensibilidade	Especificidade	VP	FP	FN	VN	Acurácia
Hong 2025a	95,3%	92,7%	181	142	9	1.813	93,0%
Hong 2025b	95,2%	86,7%	360	56	18	366	90,8%
Ostrovsky 2025	76,2%	93,7%	141	77	44	1.138	91,4%
Huang 2023	84,8%	98,5%	139	5	25	331	94,0%
Huang 2025	72,7%	100,0%	24	22	9	97.596	100,0%
Akçay 2025	70,9%	96,4%	78	4	32	106	83,6%
Ciflik 2026	100,0%	91,4%	30	18	0	192	92,5%
Güzel 2026	22,0%	95,0%	523	415	1.856	7.881	78,7%
Khovanova 2026	31,6%	93,3%	12	3	26	42	65,1%

Fonte: Elaborado pelo autor (2026), com base nos estudos primários citados.


A avaliação do risco de viés e preocupações com a aplicabilidade pelo instrumento QUADAS-2 está resumida na Tabela 3. Os estudos Akçay 2025 [13] e Khovanova 2026 [14] foram julgados com alto risco de viés no domínio “Seleção de Pacientes” por adotarem desenhos caso-controle balanceados que induzem viés de espectro e não refletem a prevalência clínica real. Sete estudos apresentaram risco incerto no domínio “Teste Índice” pela ausência de thresholds de corte textuais declarados de forma unívoca em seus métodos de prompt. A distribuição detalhada das avaliações de risco de viés e preocupações de aplicabilidade para cada estudo primário individual pode ser visualizada na Figura 2, e o resumo geral das avaliações por domínio está ilustrado na Figura 3.

Tabela 3 – Avaliação da Qualidade Metodológica dos Estudos pelo Instrumento QUADAS-2 (N=12)


Estudo	Risco de Viés				Preocupações com Aplicabilidade		
	Seleção	Teste Índice	Padrão Ref.	Fluxo/Tempo	Seleção	Teste Índice	Padrão Ref.
Hong 2025a	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo
Hong 2025b	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo
Ostrovsky 2025	Baixo	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo
Huang 2023	Baixo	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo
Huang 2025	Baixo	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo
Akçay 2025	Alto	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo
Ciflik 2026	Baixo	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo
Lee 2025	Baixo	Baixo	Incerto	Baixo	Baixo	Baixo	Baixo
Güzel 2026	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo
Khovanova 2026	Alto	Incerto	Baixo	Incerto	Baixo	Baixo	Baixo
Bai 2026	Incerto	Baixo	Baixo	Baixo	Baixo	Baixo	Baixo
Bulut 2025	Incerto	Incerto	Baixo	Alto	Baixo	Baixo	Baixo

Fonte: Elaborado pelo autor (2026).

Figura 2 – QUADAS-2: Avaliação Individual por Estudo e Domínio.



Fonte: Elaborado pelo autor (2026).

Figura 3 – QUADAS-2: Resumo por Domínio (N=12).

Fonte: Elaborado pelo autor (2026).

3.2 Meta-análise Exploratória: Pool Principal (N=9)

A síntese quantitativa das estimativas de acurácia diagnóstica do pool principal bivariado de N=9 estudos (113.714 exames) é apresentada na Tabela 4. O modelo bivariado estimou uma sensibilidade agrupada de 78,1% (IC 95%: 54,9–91,3%) e uma especificidade agrupada de 96,8% (IC 95%: 89,1–99,1%). A Razão de Verossimilhança Positiva (RV+) foi estimada em 24,10, enquanto a Razão de Verossimilhança Negativa (RV-) foi de 0,226. A área sob a curva (AUC) SROC foi calculada em 0,953. As estimativas individuais e a sensibilidade agrupada de efeitos aleatórios são apresentadas no Forest Plot da Figura 4. De forma análoga, a dispersão das especificidades individuais e a especificidade agrupada correspondente estão ilustradas no Forest Plot da Figura 5. A curva SROC (Summary Receiver Operating Characteristic) hierárquica e suas respectivas regiões de confiança e predição são exibidas na Figura 6.


Tabela 4 – Resultados Meta-analíticos Agrupados do Pool Principal (N=9)

Métrica	Estimativa	Intervalo de Confiança (IC 95%)
Sensibilidade Agrupada	78,1%	54,9%–91,3%
Especificidade Agrupada	96,8%	89,1%–99,1%
Razão de Verossimilhança Positiva (RV+)	24,10	—
Razão de Verossimilhança Negativa (RV-)	0,226	—
Estudos Incluídos	9	—
Total de Participantes	113.714	—

Fonte: Elaborado pelo autor (2026), com base no modelo bivariado de Reitsma, método REML.


O intervalo de predição de 95% estimado para a sensibilidade foi de 6,4% a 99,5%, enquanto para a especificidade variou de 18,1% a 100,0% ($\tau_{\text{sens}} = 1,583$; $\tau_{\text{fpr}} = 1,966$). A elevada amplitude dos intervalos de predição evidencia a alta variabilidade e heterogeneidade intrínseca do desempenho de leitura visual entre os diferentes modelos avaliados no pool, indicando que não é possível assegurar um patamar fixo de acurácia diagnóstica em novos ambientes sem controle rigoroso dos modelos.

Figura 4 – Forest Plot da Sensibilidade Agrupada (N=9, Raw 2×2).




Fonte: Elaborado pelo autor (2026).

Figura 5 – Forest Plot da Especificidade Agrupada (N=9, Raw 2×2).



Fonte: Elaborado pelo autor (2026).

Figura 6 – Curva SROC Hierárquica e Regiões de Confiança e Predição: Pool Principal (N=9).



Fonte: Elaborado pelo autor (2026).

3.3 Análises de Sensibilidade

As análises de sensibilidade executadas para avaliar a robustez das estimativas do ponto sumário são sumarizadas na Tabela 5.

Tabela 5 – Resultados das Análises de Sensibilidade (Robustez)

Cenário	Estudos (N)	Participantes	Sens (%)	IC 95%	Spec (%)	IC 95%	RV+	RV-	AUC
1. Pool completo (N=9)	9	113.714	78,1	54,9–91,3	96,8	89,1–99,1	24,10	0,226	0,953
A. Sem Güzel 2026	8	103.039	83,1	65,3–92,7	97,0	88,0–99,3	27,28	0,175	0,954
B. Sem Huang 2025	8	16.063	79,2	52,8–92,8	93,7	91,0–95,6	12,54	0,222	0,950
C. Sem Ambos	7	5.388	84,6	64,8–94,3	93,7	90,2–96,0	13,41	0,164	0,958
D. Sem Alto Risco	7	113.411	83,7	59,4–94,8	97,2	86,8–99,5	29,83	0,167	0,963
E. Subgrupo PTX	5	110.931	79,0	40,0–95,5	98,0	83,8–99,8	38,87	0,214	0,962

Fonte: Elaborado pelo autor (2026).

A exclusão de Güzel 2026 (Cenário A) elevou a sensibilidade agrupada para 83,1% (IC 95%: 65,3–92,7%), demonstrando o forte efeito deste estudo de baixa sensibilidade


diagnóstica sobre o pool geral.

A exclusão de Huang 2025 (Cenário B) reduziu a especificidade agrupada de 96,8% para 93,7% (IC 95%: 91,0–95,6%), o que comprova que a especificidade próxima a 100% do pool principal era artificialmente inflada pelo peso amostral maciço ($N=97.651$) e baixa prevalência de doença deste estudo.

A exclusão simultânea de ambos os extremos (Cenário C) resultou em uma sensibilidade de 84,6% e especificidade de 93,7%, o qual representa a estimativa de acurácia mais estável e representativa para ambientes clínicos habituais onde a prevalência de doença situa-se entre 5% e 20%.

3.4 Heterogeneidade

A heterogeneidade quantificada pelo índice I^2 bivariado de Zhou-Dendukuri foi de 74,6% no pool principal completo. Pelo método de Holling não ajustado, a variabilidade situou-se entre 89,1% e 99,7%, enquanto o método ajustado pelo tamanho amostral situou-se entre 9,1% e 21,9%. A acentuada divergência entre as versões ajustada e não ajustada reflete o peso da assimetria amostral do pool, sobretudo a dominância de Huang 2025. A exclusão simultânea dos dois extremos de volume (Cenário C) reduz o índice de Zhou-Dendukuri de 74,6% para 52,0%, indicando que parcela relevante — porém não a totalidade — da heterogeneidade se associa à dispersão de tamanhos amostrais e prevalências. Ressalte-se, contudo, que a heterogeneidade não diminui em todos os recortes: nos Cenários D (exclusão de estudos com alto risco de viés) e E (subgrupo restrito a pneumotórax), o índice de Zhou-Dendukuri sobe para 86,4% e 86,6%, respectivamente. Assim, a variabilidade remanescente não é atribuível apenas ao tamanho amostral e persiste mesmo em subconjuntos clinicamente mais homogêneos, reforçando a leitura de que a inconsistência de desempenho entre modelos e tarefas é intrínseca à literatura primária. A análise do viés de publicação e da assimetria de relato foi realizada graficamente através do Funnel Plot apresentado na Figura 7, complementada pelo teste de regressão de Deeks ($p = 0,008$), cujo resultado é aqui reportado em caráter estritamente descritivo. Com menos de 10 estudos, o Cochrane-DTA não recomenda a realização nem a interpretação formal desse teste, que carece de poder estatístico adequado; ademais, ele é fortemente sensível à acentuada heterogeneidade de tamanho amostral do pool — sobretudo ao peso desproporcional de Huang 2025. Por essas razões, o valor obtido não deve ser lido como evidência de viés de publicação, refletindo mais provavelmente um efeito de tamanho de amostra.

Figura 7 – Funnel Plot para Avaliação de Viés de Publicação e Assimetria de Relato.

Fonte: Elaborado pelo autor (2026).

3.5 Análise Exploratória por Subgrupos

3.5.1 Por Arquitetura

A comparação de médias aritméticas simples de acurácia diagnóstica entre as arquiteturas evidenciou perfis distintos. Os modelos baseados em Large Language Models (LLM de imagem de propósito geral, $N=2$ estudos: Huang 2023, Huang 2025) alcançaram sensibilidade média de 78,7% e especificidade média de 99,2%. Por outro lado, os modelos multimodais com visão ativa (Vision-Language Models, $N=7$ estudos: Hong 2025a, Hong 2025b, Ostrovsky 2025, Akçay 2025, Ciflik 2026, Güzel 2026, Khovanova 2026) obtiveram sensibilidade média de 70,2% e especificidade média de 92,8%, como sintetizado na Tabela 6. Ressalva-se que essa comparação é meramente descritiva: baseia-se em médias aritméticas não ponderadas, depende da classificação arquitetural derivada da nomenclatura dos estudos primários (Seção 2.2) e apoia-se em apenas dois estudos no braço LLM, não autorizando teste formal de diferença entre arquiteturas.

A queda na sensibilidade média observada nos VLMs decorre da incorporação dos dados de Güzel 2026 e Khovanova 2026. Em contraste, os modelos de domínio específico adaptados para radiologia (como o KARA-CXR nos estudos Hong 2025a/b/c e


o MedRAX e BiomedCLIP em Khovanova 2026) demonstraram patamares consistentes de acurácia clínica comparados a modelos genéricos. A distribuição conjunta das taxas de sensibilidade e especificidade ponderadas pelo tamanho da amostra de cada estudo é ilustrada no Bubble Plot da Figura 8, enquanto o desempenho médio das sensibilidades e especificidades de cada arquitetura de IA é comparado no gráfico da Figura 9.

Tabela 6 – Análise Exploratória por Subgrupo de Arquitetura (N=9)

Arquitetura	Estudos (N)	Sensibilidade Média	Especificidade Média	Estudos Incluídos
LLM	2	78,7%	99,2%	Huang 2023, Huang 2025
VLM	7	70,2%	92,8%	Hong 2025a, Hong 2025b, Ostrovsky 2025, Akçay 2025, Ciflik 2026, Güzel 2026, Khovanova 2026


Fonte: Elaborado pelo autor (2026).

Figura 8 – Bubble Plot: Sensibilidade × Especificidade × Tamanho da Amostra.



Fonte: Elaborado pelo autor (2026).

Figura 9 – Comparativo de Desempenho por Arquitetura de IA: VLM vs. LLM.



Fonte: Elaborado pelo autor (2026).

3.5.2 Por Condição Clínica

O desempenho variou significativamente conforme a patologia avaliada, cujos estudos e exames por subgrupo de condição clínica estão descritos na Tabela 7. Para a detecção de tuberculose (Hong 2025b), a sensibilidade individual foi elevada (95,2%, com especificidade de 86,7%), refletindo o bom desempenho do modelo em identificar padrões consolidation e infiltrados típicos de triagem epidemiológica. Para pneumonia (Ostrovsky 2025), a sensibilidade foi de 76,2% e especificidade de 93,7%.¹ O pior desempenho geral ocorreu na detecção de nódulos pulmonares (Khovanova 2026), no qual a sensibilidade caiu para apenas 31,6%, evidenciando a extrema dificuldade das IAs generativas em identificar lesões nodulares pequenas e isoladas.

¹O subconjunto de 1.400 imagens do *NIH Chest X-ray* utilizado por Ostrovsky 2025 abrange sete categorias patológicas (200 imagens cada). A matriz 2×2 aqui adotada refere-se especificamente à tarefa de pneumonia (sensibilidade 76,2%, especificidade 93,7%, conforme a tabela do artigo); consequentemente, os casos classificados como “negativos” incluem imagens de outras patologias além de exames estritamente normais, e o total de positivos reconstruído (185) aproxima-se dos 200 exames rotulados como pneumonia.

Tabela 7 – Análise Exploratória por Subgrupo de Condição Clínica (N=9)

Condição Clínica	Estudos (N)	N Total Exames	Estudos Incluídos
Pneumotórax	5	110.931	Hong 2025a, Huang 2025, Akçay 2025, Ciflik 2026, Güzel 2026
Outras Condições	4	2.783	Hong 2025b, Ostrovsky 2025, Huang 2023, Khovanova 2026

Fonte: Elaborado pelo autor (2026).

3.5.3 Por Tamanho e Gravidade da Lesão

A acurácia dos modelos generativos mostrou-se altamente dependente do tamanho físico da patologia. No estudo de Akçay 2025 [13], a área sob a curva (AUC) do ChatGPT-4o para diagnosticar pneumotórax caiu drasticamente de 0,894 em lesões classificadas como grandes (distância hilum-pleura ≥ 2 cm) para apenas 0,439 em lesões pequenas (< 2 cm), indicando desempenho inferior ao acaso em patologias sutis. No estudo em larga escala de Güzel 2026 [11] (N=10.675 CXRs), a baixíssima sensibilidade global do GPT-4o, Gemini 2 e Claude 4 (variando entre 16,0% e 36,0%) foi atribuída diretamente à incapacidade dos modelos de identificar pequenos focos de colapso pulmonar no conjunto de dados SIIM-ACR.

3.5.4 Por Grupo Demográfico

A avaliação de subgrupos demográficos evidenciou viés etário relevante. No estudo retrospectivo de Bulut 2025 [17] avaliando o diagnóstico de pneumotórax em um hospital terciário, a acurácia dos três modelos avaliados (ChatGPT-4o, Gemini 2.0 e Claude 3.5) decaiu de forma vertiginosa no subgrupo pediátrico (idade ≤ 12 anos), registrando taxas de acurácia entre 12,5% e 20,8%, em comparação ao subgrupo de pacientes adultos (57,4% a 69,6%). Esta diferença decorre de fatores anatômicos específicos da infância (estruturas ósseas mais finas, timo proeminente e maior frequência de artefatos de choro/movimentação), para os quais os modelos genéricos não receberam treinamento adequado.

3.6 Impacto no Fluxo de Trabalho (Workflow) Clínico

A introdução de laudos estruturados preliminares gerados por IA foi associada a melhorias significativas de fluxo. No reader study multicêntrico de Hong 2025c [21] (N=758 exames avaliados por 5 radiologistas), a assistência do modelo de IA específico (KARA-CXR) reduziu o tempo médio de interpretação e emissão de laudo de 34,2 segundos ($\pm 20,4$) para 19,8 segundos ($\pm 12,5$) por exame, representando um ganho de eficiência de aproximadamente 42% ($P < 0,001$). A qualidade do relatório final manteve-se equivalente ou superior à leitura humana padrão.

Além disso, a sensibilidade dos médicos em detectar condições desafiadoras aumentou significativamente com o suporte da IA: a sensibilidade para identificar lesões pleurais subiu de 77,7% para 87,4% ($P < 0,001$) e para alargamento de silhueta medias-tinal aumentou de 84,3% para 90,8% ($P < 0,001$). A taxa de aceitação sem modificações

(acceptability) do laudo gerado pela IA específica foi de 70,5% para o modelo KARA-CXR (comparado a apenas 29,6% para o GPT-4V de propósito geral), demonstrando que IAs customizadas possuem linguagem clínica superior e reduzem a sobrecarga de digitação do radiologista.

3.7 Qualidade Textual e Alucinações nos Laudos Gerados

Apesar dos benefícios de velocidade, os laudos gerados exibiram inconsistências descritivas e alucinações textuais. No estudo de Hong 2025b [19] avaliando triagem de tuberculose, a taxa de erro de localização anatômica lateral da IA foi de 36,7% (acurácia de localização de apenas 63,3%), com o modelo gerando laudos que descreviam consolidações apicais no pulmão direito quando a lesão real localizava-se no pulmão esquerdo. Adicionalmente, em análises qualitativas de factualidade (como em ReXamine-Global [22]), os modelos apresentaram alucinações graves, como descrever fraturas costais e níveis hidroaéreos que não constavam nas imagens, ou citar a presença de um tubo endotraqueal bem posicionado em radiografias de pacientes que não estavam intubados.

4 DISCUSSÃO

4.1 Interpretação das Estimativas


Os resultados da meta-análise apontam para estimativas de sensibilidade (78,1%) e especificidade (96,8%) robustas, sugerindo que a tecnologia generativa atingiu um nível de discernimento visual comparável a radiologistas gerais em tarefas de triagem de exames normais. Contudo, a elevada dispersão expressa no intervalo de predição [6,4%; 99,5%] indica que o ponto sumário não deve ser interpretado como uma garantia de desempenho estática. A grande variação decorre do desalinhamento de construto entre os estudos incluídos, nos quais as tarefas de diagnóstico variam desde a detecção simples de pneumotórax até a caracterização clínica complexa de infiltrados e nódulos pulmonares.

4.2 Implicações da Dominância Amostral

A análise de dominância amostral revelou que as altas estimativas de especificidade do pool completo são fortemente influenciadas pelo estudo prospectivo de Huang 2025 [12], que contribui com 97.651 dos 113.714 participantes (85,9% do peso meta-analítico).² Como a prevalência de pneumotórax na coorte de Huang 2025 foi extremamente baixa (0,03%, correspondendo a apenas 33 casos positivos em quase 100.000 exames), a especificidade de 100% obtida pelo modelo influenciou pesadamente a estimativa agrupada. A análise co-primária (Cenário B, sem Huang 2025) restabelece a especificidade real em 93,7%, a qual deve ser adotada como o parâmetro real para cálculos de custos regulatórios e triagem clínica.

²O estudo de Huang 2025 não apresenta uma matriz 2×2 única para o desfecho de pneumotórax. As células aqui empregadas foram reconstruídas a partir de duas sub-análises reportadas no artigo: a coorte de sensibilidade (33 pneumotórax inesperados que preencheram os critérios de priorização, dos quais 24 foram sinalizados, resultando em VP=24 e FN=9) e a coorte de precisão do sistema de sinalização (78 exames sinalizados, dos quais 56 verdadeiros, resultando em FP=22); os verdadeiros negativos (97.596) foram obtidos por complemento sobre os 97.651 exames rastreados. O par sensibilidade 72,7%/especificidade 99,9% corresponde ao resultado principal declarado pelos autores.

Figura 10 – Nomograma de Fagan: Probabilidades Pós-teste para Cenários Clínicos.



Fonte: Elaborado pelo autor (2026).

4.3 Perfis por Arquitetura

Os perfis diagnósticos revelaram um padrão de complementaridade de acordo com a arquitetura do modelo. Enquanto os LLMs de propósito geral mostraram maior especificidade média (99,2%), a sensibilidade agrupada tendeu a ser superior nos VLMs adaptados para radiologia (como o KARA-CXR). Isso indica que modelos treinados especificamente em laudos médicos reais desenvolvem um vocabulário clínico mais rico e maior sensibilidade para pequenos detalhes textuais, ao passo que modelos proprietários de propósito geral (GPT-4o, Gemini 2) aplicam thresholds internos de classificação mais conservadores, resultando em menor sensibilidade diagnóstica.

Esse comportamento conservador é especialmente evidente em modelos proprietários

de propósito geral avaliados em conjuntos de dados desafiadores. No estudo de Güzel 2026 [11], a sensibilidade de modelos como Gemini 2 Pro e Claude 4 Sonnet para detecção de pneumotórax desabou para patamares entre 16,0% e 36,0% (com sensibilidade média de 22,0%), enquanto a especificidade manteve-se consistentemente acima de 95,0%. Um padrão semelhante foi documentado por Khovanova 2026 [14], em que o Claude 3.7 Sonnet obteve sensibilidade de apenas 31,6% na detecção de nódulos pulmonares.

Este fenômeno pode ser explicado pelas restrições de segurança impostas durante o treinamento desses modelos comerciais por meio de Aprendizado por Reforço com Feedback Humano (RLHF). Para mitigar alucinações (geração de achados inexistentes ou falsos positivos), os desenvolvedores aplicam penalidades severas à geração de relatórios espúrios. Diante de qualquer incerteza visual em uma imagem sutil ou pouco conspícua, o modelo adota um threshold de decisão extremamente alto, preferindo classificar o exame como "dentro dos limites da normalidade" ou "sem alterações agudas". Embora essa estratégia minimize falsos alarmes (alta especificidade), ela induz uma taxa inaceitável de falsos negativos (baixa sensibilidade), limitando a utilidade desses sistemas como ferramentas autônomas de triagem médica.

4.4 O Impacto da Engenharia de Prompts

A formulação das instruções fornecidas às IAs generativas atua como o principal threshold de decisão clínica do sistema. Nos estudos incluídos, prompts instrucionais curtos que forçavam respostas binárias rígidas (como "pneumotórax presente: 1 ou 0", adotado em Güzel 2026 [11] e Akçay 2025 [13]) resultaram em taxas de sensibilidade sensivelmente inferiores às obtidas em estudos onde os prompts permitiam a geração de laudos em texto livre (como nos estudos de Hong 2025a/b). Adicionalmente, quando o prompt inclui o contexto clínico prévio (histórico de dor torácica ou suspeita de trauma), observa-se aumento de sensibilidade, pois o modelo de linguagem ancora sua atenção em regiões de maior probabilidade, de forma similar ao raciocínio diagnóstico de um radiologista humano.

4.5 Ferramenta Diagnóstica Isolada vs. Colaboração Humano-IA

A evidência cumulativa demonstra que os modelos multimodais de IA generativa não apresentam segurança científica para uso autônomo na prática clínica. A baixa sensibilidade demonstrada na detecção de lesões sutis (como nódulos pulmonares em Khovanova 2026 [14] ou pneumotórax pequeno em Akçay 2025 [13]) inviabiliza o emprego dessas ferramentas como mecanismos de exclusão de diagnóstico (rule-out). O papel clinicamente seguro e suportado pelas evidências é o de segunda leitura assistida (copiloto). Nesse modelo de uso colaborativo, a IA funciona como um revisor preliminar que agiliza o laudo e previne omissões por fadiga visual do radiologista, mantendo a responsabilidade final do diagnóstico sob supervisão e validação humana obrigatória.

No entanto, a transição de modelos tradicionais de redes neurais convolucionais (CNNs) para modelos multimodais generativos introduz o chamado **“gap de explicabilidade”**. As CNNs clássicas de classificação visual costumam ser acompanhadas por mapas de calor baseados em ativação (como o Grad-CAM), os quais fornecem uma explicabilidade espacial direta ao apontar a região exata do pixel que determinou a inferência da IA. Em contrapartida, as IAs generativas produzem laudos textuais fluentes em linguagem livre que descrevem a patologia de forma descritiva, mas carecem de mecanismos nativos de ancoragem espacial visual (**“grounding”**). Essa lacuna dá origem a um tipo inédito de erro na radiologia computadorizada: o **“diagnóstico correto com atribuição espacial incorreta”**. Como observado no estudo de triagem de tuberculose de Hong 2025b [19], a IA gerou laudos descrevendo consolidações no pulmão direito quando a lesão real localizava-se no pulmão esquerdo, registrando uma taxa de erro de lateralidade de 36,7%. Esse descompasso semântico-visual exige que o radiologista humano atue não apenas validando a presença da patologia sugerida, mas auditando meticulosamente a coerência espacial descrita pelo modelo.

Adicionalmente, os ganhos expressivos de eficiência no fluxo de trabalho clínico — como a redução de 42% no tempo de digitação e leitura documentada por Hong 2025c [21] — trazem consigo o risco latente do **“viés de automação”** associado à fadiga cognitiva. Sob condições de sobrecarga crônica de trabalho e exaustão mental (conforme discutido na Seção 1.1), o radiologista tende a aceitar passivamente o laudo preliminar gerado pela IA para acelerar a liberação do exame, reduzindo seu nível de escrutínio ativo sobre a imagem. Evidência longitudinal corrobora essa preocupação: no estudo multileitor longitudinal de Hong et al. [23] (756 radiografias interpretadas por cinco radiologistas em sete lotes sequenciais ao longo de um mês) — publicação distinta do *reader study* de Hong 2025c [21], embora oriunda do mesmo grupo e do mesmo sistema de IA —, a taxa de aceitação dos laudos de IA sem modificação aumentou progressivamente de 54,6% para 60,2% ($P < 0,001$) à medida que os leitores se habituavam à ferramenta, enquanto a concordância e a qualidade permaneceram estáveis nos exames normais mas oscilaram nos casos anormais — justamente os que mais demandam escrutínio independente. Esse comportamento passivo pode induzir o fenômeno de **“co-omissão”**: caso a IA generativa falhe em relatar um achado sutil ou pequeno (cenário frequente devido ao gargalo de compressão de 8 bits), o radiologista, induzido pelo relatório “normal” da IA, também deixará de detectar a patologia. Assim, a colaboração Humano-IA só se traduz em incremento real de segurança se houver salvaguardas de fluxo que forcem o médico a realizar uma leitura visual independente antes de visualizar a sugestão textual da máquina, mitigando a transferência sistemática dos erros do algoritmo para o diagnóstico do paciente.

4.6 Lacunas da Literatura Primária

A literatura primária apresenta lacunas estruturais significativas que limitam o alcance das sínteses quantitativas atuais. Em primeiro lugar, destaca-se o ****gargalo de compressão e resolução da imagem****. A radiologia digital utiliza nativamente arquivos no padrão DICOM (*Digital Imaging and Communications in Medicine*), que possuem profundidades de cor variando de 12 a 16 bits, o que corresponde a uma escala de cinza com 4.096 a 65.536 níveis de intensidade. Além disso, a prática radiológica humana baseia-se no ajuste interativo de brilho e contraste (*windowing* ou janelamento) no monitor diagnóstico, permitindo ao médico realçar linhas pleurais sutis ou pequenas atenuações nodulares pulmonares.

Quase a totalidade dos estudos primários avaliados, no entanto, submeteu imagens convertidas para formatos comuns de internet de 8 bits (JPEG ou PNG), que oferecem apenas 256 níveis de cinza, e frequentemente redimensionadas para resoluções reduzidas (ex: 224×224, 384×384 ou 512×512 pixels) para se adequarem às janelas de contexto e limitações computacionais dos encoders visuais dos VLMs. Esta compressão e perda de profundidade de bits causam uma ****destruição física de informações de alta frequência espacial****, eliminando o contraste tênue necessário para visualizar descolamentos pleurais finos (como no pneumotórax sutil) ou densidades de tecidos moles pequenas (nódulos menores que 1 cm). Esse fator explica por que o desempenho da IA decaiu de forma tão acentuada para lesões pequenas nos estudos de Akçay 2025 [13] e Güzel 2026 [11], revelando que a baixa acurácia em patologias sutis é, em grande parte, uma limitação física da qualidade da imagem de entrada fornecida ao modelo, e não apenas um déficit cognitivo de interpretação.

Em segundo lugar, observa-se uma quase total ausência de dados clínicos estruturados e integrados (sintomas, dados laboratoriais) nos conjuntos de teste primários, forçando os modelos a realizar leituras visuais cegas desprovidas de contexto. Na prática clínica, o histórico do paciente (ex: "tabagista pesado com tosse produtiva" ou "pós-procedimento de acesso venoso central") atua como um prior bayesiano que orienta a busca visual do radiologista; a privação desse contexto penaliza injustamente os modelos generativos.

Por fim, a falta de publicação das matrizes de confusão completas e dos logs de prompt em repositórios públicos (como observado em Lee 2025 [15] e Bulut 2025 [17]) impede a reprodutibilidade dos resultados. Trabalhos recentes de alto impacto publicados em periódicos como *Nature Communications* (Bai et al. 2026 [16], propondo o framework Janus-Pro-CXR baseado no backbone DeepSeek) começam a introduzir o reporte padronizado de curvas ROC e áreas sob a curva por achado específico, mas ainda há escassez de matrizes 2×2 brutas.

4.7 Limitações

As limitações deste estudo meta-analítico incluem:

1. Processo de revisor único nas etapas de julgamento: embora a triagem de títulos e resumos tenha sido automatizada e determinística (TF-IDF), a avaliação de elegibilidade por texto completo, a extração das matrizes de contingência 2×2 e o julgamento QUADAS-2 foram conduzidos por um único revisor. A ausência de um segundo revisor independente e cego impede o cálculo da concordância interavaliador (kappa de Cohen) e expõe essas etapas a viés de seleção e de extração, constituindo a principal limitação metodológica desta revisão; a replicação independente requer a incorporação de um segundo avaliador;
2. Dominância amostral extrema do estudo Huang 2025, condicionando a especificidade agrupada;
3. Intervalo de predição de sensibilidade muito amplo, limitando a generalização do ponto sumário;
4. Viés de independência estatística pelo uso de dados originados do mesmo grupo e sistema (cluster Hong 2025a/b, com Hong 2025c e o reader study longitudinal de Hong et al. [23] reforçando a dependência entre publicações do mesmo grupo);
5. Poucos estudos no subgrupo de LLM puro (N=2), impedindo testes formais de heterogeneidade por arquitetura;
6. Cobertura geográfica restrita a exames de instituições dos Estados Unidos, Coreia do Sul, Turquia e Rússia, reduzindo a validade externa para populações da América Latina;
7. Avaliação retrospectiva predominante nos estudos bivariados incluídos.

4.8 Implicações Regulatórias e Governança

No cenário regulatório brasileiro, sistemas de auxílio diagnóstico baseados em inteligência artificial são classificados como Software como Dispositivo Médico (SaMD) e estão sujeitos à regulação sanitária da ANVISA, sob as diretrizes da RDC 657/2022. Sob esta resolução, as ferramentas de IA generativa e multimodal necessitam de validação clínica retrospectiva e prospectiva multicêntrica em dados nacionais antes de serem aprovadas para fins comerciais e assistenciais. A ausência de validação em exames de pacientes do sistema público de saúde brasileiro (SUS) e as frequentes alucinações descritas reforçam que, sob as normas da ANVISA, esses sistemas não reúnem os requisitos necessários para uso autônomo, sendo sua indicação de uso obrigatoriamente restrita a ferramentas de apoio diagnóstico com revisão humana compulsória.

5 CONCLUSÃO

A presente revisão sistemática e meta-análise avaliou a acurácia diagnóstica de modelos de IA generativa e multimodal na interpretação de radiografias de tórax. O pool principal de N=9 estudos totalizando 113.714 participantes estimou uma sensibilidade agrupada de 78,1% e uma especificidade agrupada de 96,8%. A elevada especificidade média obtida é condicionada pela dominância de um único estudo prospectivo de baixíssima prevalência (Huang 2025), ajustando-se para 93,7% na análise co-primária de robustez. A variabilidade observada entre os estudos primários resultou em intervalos de predição amplos, indicando alta incerteza preditiva em novos ambientes clínicos.

Recomenda-se a adoção de um padrão mínimo de reporte metodológico em estudos futuros (framework PIRT-IA), contemplando a disponibilização de matrizes 2×2 completas por threshold avaliado, descrição do prompt e temperatura de inferência, especificação do formato de imagem (DICOM vs. PNG) e a presença de controle clínico de alucinações. O uso clínico desses modelos generativos mostra-se inviável de forma autônoma ou para fins de exclusão rápida (rule-out) de patologias agudas devido à baixa sensibilidade diagnóstica demonstrada para lesões sutis e pequenas. Contudo, seu papel assistencial como segunda leitura acoplada à revisão humana obrigatória apresenta robustez estatística e científica, proporcionando redução no tempo de emissão de laudos e mitigação de erros por fadiga nos serviços de radiologia. Ressalta-se, todavia, que a evidência longitudinal de aumento progressivo da aceitação passiva dos laudos gerados por IA à medida que os radiologistas se habituem à ferramenta reforça a necessidade de salvaguardas de fluxo que preservem a leitura visual independente, sob pena de transferência sistemática dos erros do modelo para o diagnóstico final.

REFERÊNCIAS

- [1] VAN GINNEKEN, B. Fifty years of computer analysis in chest imaging: rule-based, machine learning, deep learning. *Radiological Physics and Technology*, v. 10, n. 1, p. 23–32, 2017.
- [2] PARIKH, J. R.; VAN MOORE, A.; MEAD, L. et al. Prevalence of burnout of radiologists in private practice. *Journal of the American College of Radiology*, v. 20, n. 7, p. 712–718, 2023.
- [3] OSTROVSKY, A. M. Evaluating a large language model’s accuracy in chest X-ray interpretation for acute thoracic conditions. *American Journal of Emergency Medicine*, v. 93, p. 99–102, 2025.
- [4] MCINNES, M. D. F.; MOHER, D.; THOMBS, B. D. et al. Preferred Reporting Items for a Systematic Review and Meta-analysis of Diagnostic Test Accuracy Studies: The PRISMA-DTA Statement. *JAMA*, v. 319, n. 4, p. 388–396, 2018.
- [5] WHITING, P. F.; RUTJES, A. W. S.; WESTWOOD, M. E. et al. QUADAS-2: a revised tool for the quality assessment of diagnostic accuracy studies. *Annals of Internal Medicine*, v. 155, n. 8, p. 529–536, 2011.
- [6] BOSSUYT, P. M.; REITSMA, J. B.; BRUNS, D. E. et al. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. *BMJ*, v. 351, p. h5527, 2015.
- [7] KAGIYAMA, N. et al. PRIME 2.0: Proposed Requirements for Cardiovascular Imaging-Related Multimodal AI Evaluation. *JACC: Cardiovascular Imaging*, v. 19, n. 2, p. 223–251, 2026.
- [8] REITSMA, J. B.; GLAS, A. S.; RUTJES, A. W. S. et al. Bivariate analysis of sensitivity and specificity produces informative summary measures in diagnostic reviews. *Journal of Clinical Epidemiology*, v. 58, n. 10, p. 982–990, 2005.
- [9] CIFLIK, K. B.; OZDEMIR CIFLIK, B. Evaluation of multimodal large language models for pneumothorax assessment in real-world clinical scenarios. *BMC Pulmonary Medicine*, v. 26, n. 1, p. 105, 2026.
- [10] TAKWOINGI, Y.; GUO, B.; RILEY, R. D.; DEEKS, J. J. Performance of methods for meta-analysis of diagnostic test accuracy with few studies or sparse data. *Statistical Methods in Medical Research*, v. 26, n. 4, p. 1896–1911, 2017.
- [11] GÜZEL, H. E.; ÖZENBAŞ, C.; KOÇ, A. M. Large-scale evaluation of multimodal large language models for pneumothorax detection. *Diagnostic and Interventional Radiology*, 2026. doi:10.4274/dir.2026.263696.

- [12] HUANG, J.; MOOR, M.; BANERJEE, O. et al. Efficiency and Quality of Generative AI-Assisted Radiograph Reporting. *JAMA Network Open*, v. 8, n. 6, p. e2513921, 2025.
- [13] AKÇAY, O.; ÖZTÜRK, Ö. Evaluation of the effectiveness of the ChatGPT artificial intelligence application in the diagnosis of spontaneous pneumothorax on chest radiograph interpretation. *BMC Pulmonary Medicine*, v. 26, n. 1, p. 8, 2025.
- [14] KHOVANOV, D.; VASILEV, Y.; VLADZYMYRSKY, A. et al. A comparative accuracy study of multimodal LLMs, VLM and agent-based framework for pulmonary nodule detection on chest radiographs. *Frontiers in Digital Health*, v. 7, p. 1674835, 2026.
- [15] LEE, S.; YOUN, J.; KIM, H. et al. CXR-LLaVA: a multimodal large language model for interpreting chest X-ray images. *European Radiology*, v. 35, n. 6, p. 4374–4386, 2025.
- [16] BAI, Y.; ZHANG, R.; LEI, Y. et al. A DeepSeek-powered AI system for automated chest radiograph interpretation in clinical practice. *Nature Communications*, 2026. No prelo. doi:10.1038/s41467-026-72680-6.
- [17] BULUT, B.; ÖZ, M. A.; GENÇ, M. et al. New frontiers in radiologic interpretation: Evaluating the effectiveness of large language models in pneumothorax diagnosis. *PLoS ONE*, v. 20, n. 9, p. e0331962, 2025.
- [18] HONG, E. K.; HAM, J.; ROH, B. et al. Diagnostic Accuracy and Clinical Value of a Domain-specific Multimodal Generative AI Model for Chest Radiograph Report Generation. *Radiology*, v. 314, n. 3, p. e241476, 2025.
- [19] HONG, E. K.; KIM, H. W.; SONG, O. K. et al. Multimodal Generative Artificial Intelligence Model for Creating Radiology Reports for Chest Radiographs in Patients Undergoing Tuberculosis Screening. *American Journal of Roentgenology*, v. 225, n. 4, p. e2533059, 2025.
- [20] HUANG, J.; NEILL, L.; WITTBRODT, M. et al. Generative Artificial Intelligence for Chest Radiograph Interpretation in the Emergency Department. *JAMA Network Open*, v. 6, n. 10, p. e2336100, 2023.
- [21] HONG, E. K.; ROH, B.; PARK, B. et al. Value of Using a Generative AI Model in Chest Radiography Reporting: A Reader Study. *Radiology*, v. 314, n. 3, p. e241646, 2025.

- [22] BANERJEE, O.; SAENZ, A.; WU, K. et al. ReXamine-Global: A Framework for Uncovering Inconsistencies in Radiology Report Generation Metrics. *arXiv preprint arXiv:2509.01188*, 2025.
- [23] HONG, E. K.; SUH, C. H.; NUKALA, M. et al. Radiologist Interaction with Artificial Intelligence-Generated Preliminary Reports: A Longitudinal Multireader Study. *Journal of the American College of Radiology*, v. 23, n. 2, p. 292–298, 2026.